Data Quality și Master Data Management: identificarea și corectarea problemelor de calitate într-un dataset

Oct 25, 2026 · @David

Olaru David · Master: Informatică Economică, anul I, grupa 1123 · Sisteme informatice pentru inteligența afacerii

1. Introducere și întrebarea de business

Datele de vânzări ale unui magazin online sunt de încredere doar după ce le verificăm: în setul analizat, 26,86% dintre rânduri (145.572 din 541.909) au cel puțin o problemă de calitate. Lucrarea arată cum identificăm aceste probleme, cum le corectăm și ce schimbă corectarea în indicatorii de business.

Calitatea datelor (Data Quality, DQ) măsoară cât de bine se potrivesc datele cu folosirea lor: sunt complete, valide, unice și consistente. Managementul datelor master (Master Data Management, MDM) se ocupă de entitățile de referință ale firmei, precum produsele, clienții și țările, pentru ca fiecare să aibă o singură înregistrare corectă, numită „golden record". Fără ele, aceeași realitate apare în rapoarte sub mai multe forme, iar cifrele nu se mai potrivesc între departamente.

Întrebarea de business: *Cât de fiabile sunt datele de vânzări ale magazinului și cât se schimbă indicatorii principali (venit, număr de clienți, produse de top) după ce corectăm problemele de calitate?*

Obiectivele lucrării:

1. să măsurăm problemele de calitate din dataset, pe categorii;
2. să curățăm datele într-un proces repetabil, cu fiecare pas documentat;
3. să construim tabele master (produse, clienți, țări) într-un model de date de tip stea;
4. să comparăm indicatorii înainte și după curățare într-un dashboard Power BI și să interpretăm diferențele.

2. Datasetul și metodologia

Am lucrat pe setul „Online Retail" din UCI Machine Learning Repository, folosit și în proiectul de analiză a datelor de e-commerce de pe roadmap.sh. Conține tranzacțiile unui magazin online din Regatul Unit, între decembrie 2010 și decembrie 2011, în total 541.909 de rânduri și 8 coloane. Magazinul vinde în principal cadouri, iar o parte dintre clienți sunt angrosiști.

Coloană	Conținut	Tip folosit
InvoiceNo	Număr de factură (prefixul „C" marchează o anulare)	Text
StockCode	Codul produsului	Text
Description	Denumirea produsului	Text
Quantity	Cantitatea vândută pe rând	Număr întreg
InvoiceDate	Data și ora facturii	Dată/oră
UnitPrice	Preț unitar (în lire sterline)	Număr zecimal
CustomerID	Identificator client	Text
Country	Țara clientului	Text

Metoda urmează cinci etape, toate făcute în Power BI Desktop:

1. **Profilare** în Power Query (Column quality, Column distribution, Column profile, pe întregul set de date, nu pe primele 1.000 de rânduri).
2. **Marcare**: pentru fiecare problemă am adăugat o coloană logică (flag), fără a șterge nimic. Astfel putem număra problemele și păstra versiunea originală pentru comparație.
3. **Curățare**: eliminarea duplicatelor exacte și a rândurilor care nu sunt vânzări valide.
4. **MDM**: standardizarea valorilor și crearea tabelelor master `Dim_Produse`, `Dim_Clienti`, `Dim_Tari`.
5. **Modelare și raportare**: model de date de tip stea, măsuri DAX și un dashboard cu trei pagini.

Pentru comparația înainte/după am păstrat trei variante ale datelor: `Raw_Data` (brut, neatins), `Vanzari_Marcat` (brut, cu flag-uri) și `Vanzari_Curat` (după curățare).

3. Probleme de calitate identificate

Cea mai mare problemă este lipsa identificării clienților: 135.080 de rânduri (24,93%) nu au CustomerID. Celelalte probleme sunt mici ca volum, dar fiecare afectează alt indicator. Am grupat problemele după dimensiunile clasice ale calității datelor (completitudine, unicitate, validitate, consistență), descrise în literatura de specialitate (Wang și Strong, 1996; DAMA International, 2017).

Problemă	Dimensiune DQ	Rânduri afectate	% din 541.909	Efect asupra analizei
CustomerID lipsă	Completitudine	135.080	24,93%	Nu putem calcula clienți unici, frecvență sau valoare per client
Cantitate invalidă (⩽ 0)	Validitate	10.624	1,96%	Scade artificial venitul și volumul vândut
Anulări (facturi „C″)	Validitate	9.288	1,71%	Amestecă retururile cu vânzările
Duplicate exacte	Unicitate	5.268	0,97%	Aceeași linie de vânzare numărată de două ori
Coduri non-produs (POST, D, M, DOT, BANK CHARGES etc.)	Validitate	2.916	0,54%	Taxe și ajustări apar ca produse
Preț invalid (⩽ 0)	Validitate	2.517	0,46%	2.515 rânduri cu preț 0 și 2 cu preț negativ; distorsionează venitul
Descriere lipsă	Completitudine	1.454	0,27%	Produse fără denumire în rapoarte

Rânduri cu cel puțin o problemă: 145.572, adică 26,86% din total. Cifrele din tabel nu se adună la acest total, pentru că un rând poate avea mai multe probleme deodată (de exemplu, rândurile fără descriere au adesea și preț 0 și CustomerID lipsă). Duplicatele au fost numărate separat, prin diferența de rânduri înainte și după eliminarea lor.

Au apărut încă două probleme de consistență, care nu se văd într-o simplă numărare de valori lipsă:

- **Denumiri de țări neuniforme:** EIRE (Irlanda), RSA (Africa de Sud), USA și „Unspecified" erau scrise diferit față de restul sau nu indicau o țară.
- **Aceleași produse cu mai multe descrieri:** 4.148 de combinații cod–descriere pentru 3.912 coduri distincte. Pe lângă asta, unele coduri diferă doar prin majuscule (de exemplu `85123A` și `85123a`), ceea ce a dus la 109 coduri în plus.

4. Curățarea datelor și Master Data Management

Curățarea a eliminat 18.294 de rânduri (3,38%) din cele 541.909, rămânând 523.615. Am eliminat doar rândurile care nu sunt vânzări valide și am păstrat intenționat rândurile fără CustomerID, pentru că sunt vânzări reale.

Etapă	Rânduri rămase	Rânduri eliminate
Date brute	541.909	n/a
După eliminarea duplicatelor exacte	536.641	5.268
După filtrarea anulărilor, cantităților și prețurilor invalide, codurilor non-produs și descrierilor lipsă	523.615	13.026
Total eliminat		**18.294**

Decizii de curățare și motivele lor:

- **Duplicate:** am eliminat rândurile identice pe toate cele 8 coloane, deoarece sunt aceeași linie de vânzare introdusă de mai multe ori.
- **Anulări, cantități și prețuri invalide, coduri non-produs, descrieri lipsă:** am eliminat rândurile, deoarece nu reprezintă vânzări de produse. Eliminarea s-a făcut printr-un singur filtru pe coloanele flag, ca regula să fie ușor de repetat și de verificat.
- **CustomerID lipsă:** am înlocuit valoarea cu „Necunoscut" și am păstrat rândurile. Ștergerea lor ar fi eliminat un sfert din vânzări.

Golden records (MDM). Din datele curate am construit trei tabele master, fiecare cu o singură înregistrare per entitate:

Tabel master	Cheie	Înregistrări	Reguli aplicate
`Dim_Produse`	StockCode	3.803	Trim, majuscule pe cod și descriere, o singură descriere per cod (prima în ordine alfabetică)
`Dim_Clienti`	CustomerID	4.335	Clienții identificați plus o înregistrare „Necunoscut"; coloana TipClient (Identificat/Neidentificat)
`Dim_Tari`	Country	38	EIRE → Ireland, RSA → South Africa, USA → United States, Unspecified → Necunoscut

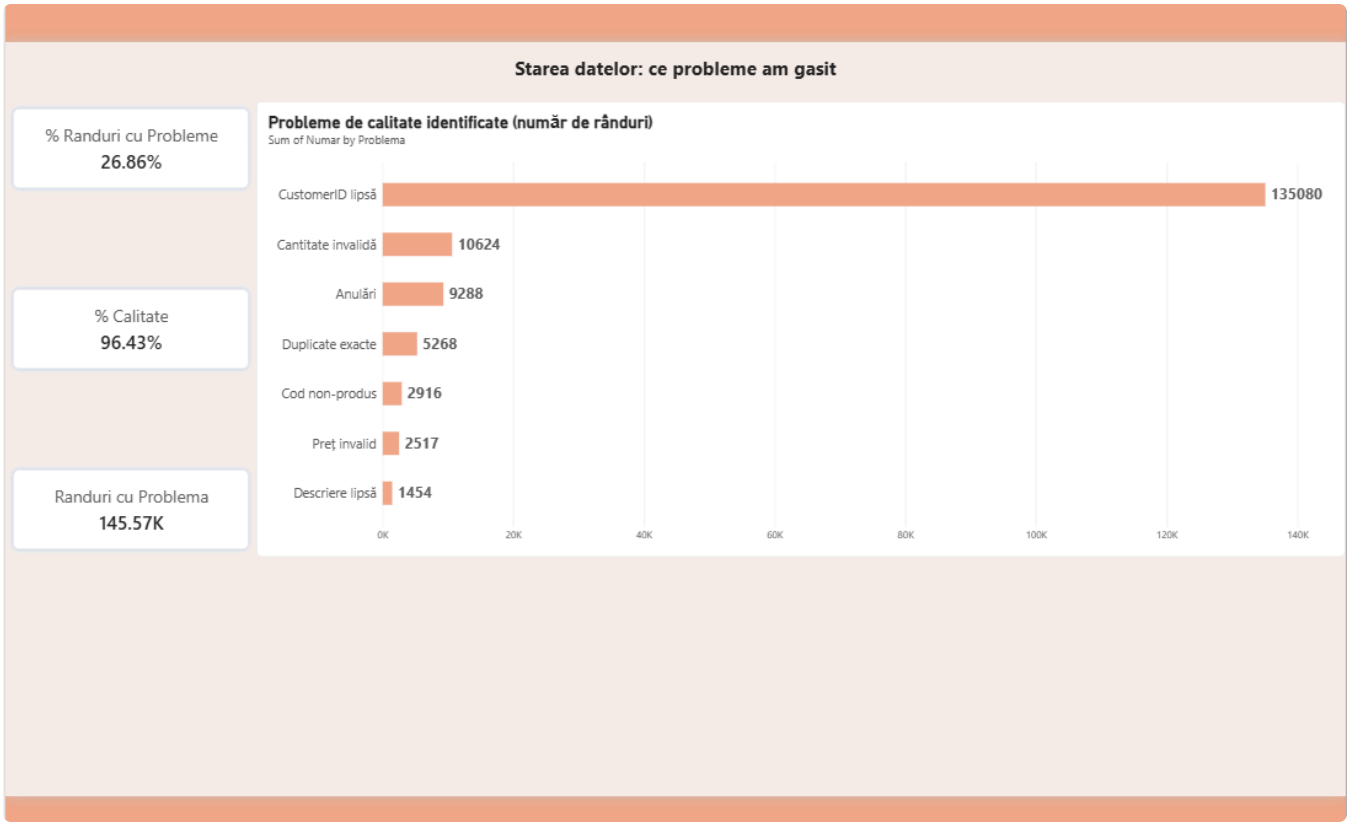
În cazul produselor, standardizarea s-a făcut în doi pași. Prima, alegerea unei singure descrieri per cod, a redus 4.148 de combinații cod–descriere la 3.912 înregistrări. A doua, trecerea codurilor în majuscule, a unit variantele scrise diferit și a redus numărul la 3.803. Deci numărul real de produse este 3.803, cu 109 mai puțin decât părea după primul pas. A fost și o condiție tehnică: cu variante de majuscule în cheie, Power BI nu a putut crea relația de tip unu-la-mulți și a cerut relație many-to-many.

Modelul de date. Cele trei tabele master sunt legate de tabelul de fapte `Vanzari_Curat` prin relații unu-la-mulți cu filtrare într-o singură direcție (model stea). Tabelele `Raw_Data` și `Vanzari_Marcat` au rămas izolate, folosite doar pentru comparația înainte/după.

5. Dashboardul Power BI și rezultate

După curățare, venitul calculat crește de la 9,75 milioane la 10,25 milioane (+500,16 mii, adică +5,1%), deși numărul de rânduri scade cu 3,4%. Dashboardul are trei pagini, fiecare cu o întrebare proprie.

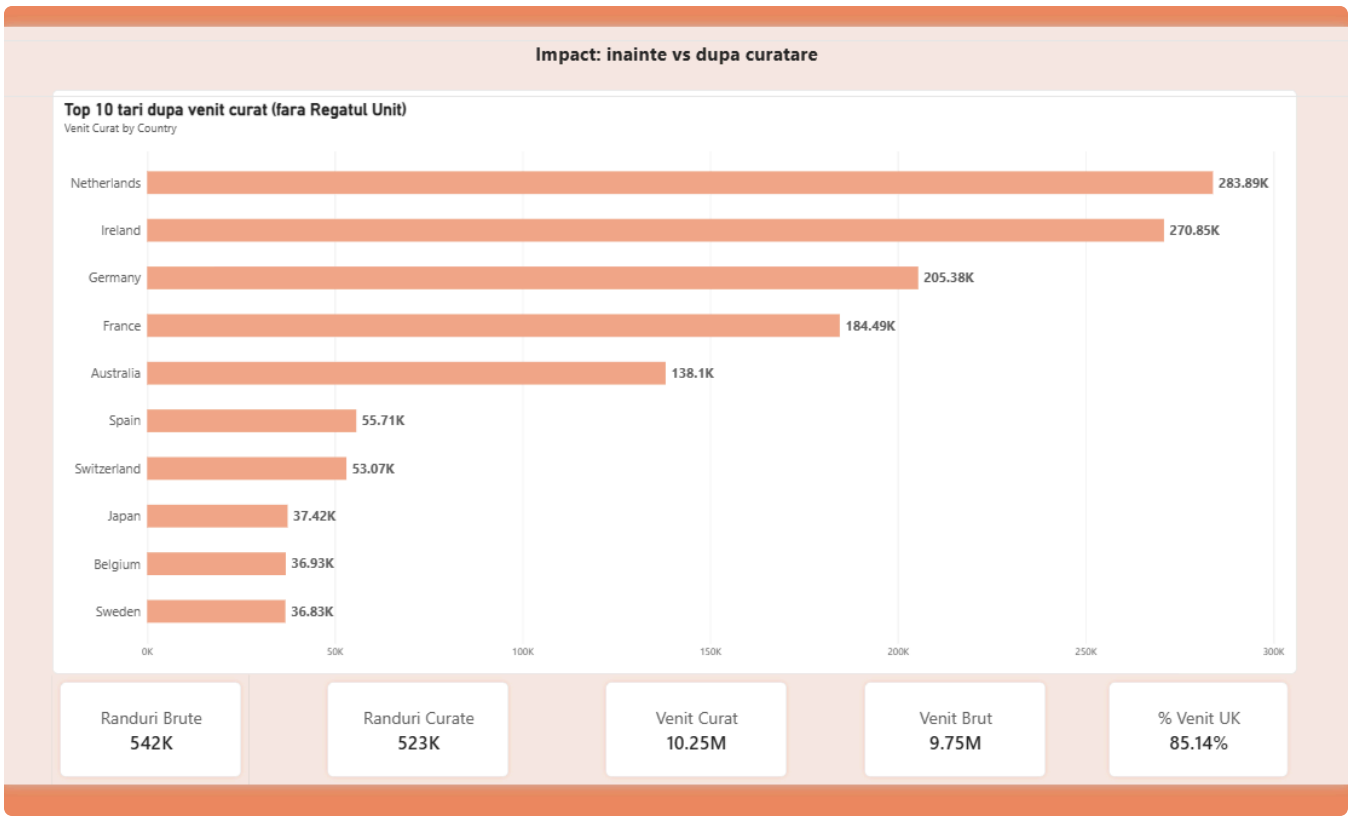
Pagina 1, „Starea datelor". Arată cele 7 probleme de calitate într-un grafic cu bare și trei indicatori: rânduri cu cel puțin o problemă (145.572), procentul lor din total (26,86%) și procentul de rânduri păstrate după curățare (96,43%).



Pagina 2, „Impact". Compară indicatorii înainte și după curățare și arată topul țărilor după venit curat, fără Regatul Unit.

Indicator	Date brute	Date curate	Diferență
Rânduri	541.909	523.615	−3,4%
Venit	9,75 mil.	10,25 mil.	+500,16 mii (+5,1%)

Regatul Unit aduce 85,14% din venitul curat, așa că piața este foarte concentrată. În topul celorlalte țări sunt Olanda (283,89 mii), Irlanda (270,85 mii), Germania (205,38 mii), Franța (184,49 mii) și Australia (138,1 mii). Faptul că Irlanda apare cu numele corect, nu ca „EIRE", este un efect direct al standardizării MDM.



Pagina 3, „Produse". Arată topul a 10 produse după venit curat, calculat pe tabelul master `Dim_Produse`. Primul este REGENCY CAKESTAND 3 TIER (174 mii), urmat de PAPER CRAFT , LITTLE BIRDIE (168 mii) și WHITE HANGING HEART T-LIGHT HOLDER (106 mii). Fiecare produs apare o singură dată, cu o singură denumire, iar cardul „Produse unice după standardizare" arată 3.803.



Măsuri DAX folosite: `Venit Brut` și `Venit Curat` (suma produsului cantitate × preț pe tabelul brut, respectiv curat), `Randuri Brute`, `Randuri Curate`, `Randuri cu Problema`, `% Randuri cu Probleme`, `% Calitate`, `% Venit UK`, `Produse Master` și `Diferenta Venit`.

6. Concluzii și limite

Datele brute nu sunt suficient de fiabile pentru raportare fără curățare: peste un sfert dintre rânduri (26,86%) au cel puțin o problemă, iar curățarea schimbă venitul raportat cu 5,1%.

Concluzii:

1. **Problema principală este completitudinea, nu erorile din tranzacții.** 135.080 de rânduri (24,93%) nu au client identificat. Magazinul poate raporta venitul corect, dar nu poate analiza comportamentul clienților pe un sfert din vânzări. Soluția este la sursă: identificarea obligatorie a clientului la comandă sau la facturare.
2. **Calitatea datelor schimbă cifra de business.** Venitul crește de la 9,75 la 10,25 milioane, pentru că în datele brute retururile și ajustările negative scad venitul. Diferența depinde de o decizie de business: dacă retururile se tratează separat sau se scad din vânzări. Decizia trebuie luată conștient și scrisă în definiția indicatorului.

3. **MDM schimbă numărul entităților.** Numărul de produse real este 3.803, nu 4.148 (combinații cod–descriere) sau 3.912 (coduri înainte de standardizarea majusculelor). Fără tabelul master, un raport pe produse ar fi împărțit vânzările aceluiași produs între mai multe denumiri.
4. **Piața este concentrată.** Regatul Unit aduce 85,14% din venitul curat, deci riscul de dependență de o singură piață este ridicat.
5. **Marcarea înainte de ștergere este o practică utilă.** Coloanele flag au permis măsurarea fiecărei probleme și păstrarea unei variante brute pentru comparație, ceea ce face procesul verificabil.

Limite ale analizei:

- **Venitul curat poate fi supraestimat.** Am eliminat facturile de anulare, dar nu și vânzările inițiale la care se referă. Un exemplu este produsul PAPER CRAFT , LITTLE BIRDIE, aflat pe locul 2 cu 168 mii, cunoscut în acest set pentru o comandă mare urmată de anulare. O analiză mai fină ar asocia fiecare anulare cu vânzarea ei și ar calcula venitul net.
- **Rândurile fără CustomerID nu au fost recuperate.** Le-am etichetat „Necunoscut", fără a încerca să deducem clientul din alte câmpuri.
- **Lista codurilor non-produs este făcută manual** (POST, D, M, DOT, BANK CHARGES și altele) și poate fi incompletă.
- **Alegerea descrierii per produs este o regulă simplă** (prima în ordine alfabetică). Într-o firmă reală, descrierea corectă ar fi stabilită de un responsabil de date (data steward).
- Datele acoperă un singur magazin și un an, deci concluziile despre piețe nu se generalizează.

7. Surse

1. Chen, D. (2015). *Online Retail* [set de date]. UCI Machine Learning Repository. https://doi.org/10.24432/C5BW33
2. Chen, D., Sain, S. L., & Guo, K. (2012). Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining. *Journal of Database Marketing & Customer Strategy Management, 19*(3), 197–208.
3. Wang, R. Y., & Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems, 12*(4), 5–33.
4. DAMA International. (2017). *DAMA-DMBOK: Data Management Body of Knowledge* (ediția a 2-a). Technics Publications.

5. roadmap.sh. *E-commerce Data Analysis* (proiect). https://roadmap.sh/projects/ecommerce-data-analysis
6. Microsoft. *Power Query: Using the data profiling tools* și *Understand star schema and the importance for Power BI*. Microsoft Learn, learn.microsoft.com.