SISTEME INFORMATICE PENTRU INTELIGENȚA AFACERII · STUDIU DE CAZ

Data Quality și Master Data Management

Identificarea și corectarea problemelor de calitate într-un dataset

Dataset: Online Retail (UCI) · Analiză în Power BI

Olaru David - grupa 1123

ÎNTREBAREA DE BUSINESS

Cât de fiabile sunt datele de vânzări și cât se schimbă indicatorii după curățare?

Venit | Clienți | Produse de top

DATELE

Online Retail: un an de vânzări online

541.909
rânduri de tranzacții

8
coloane

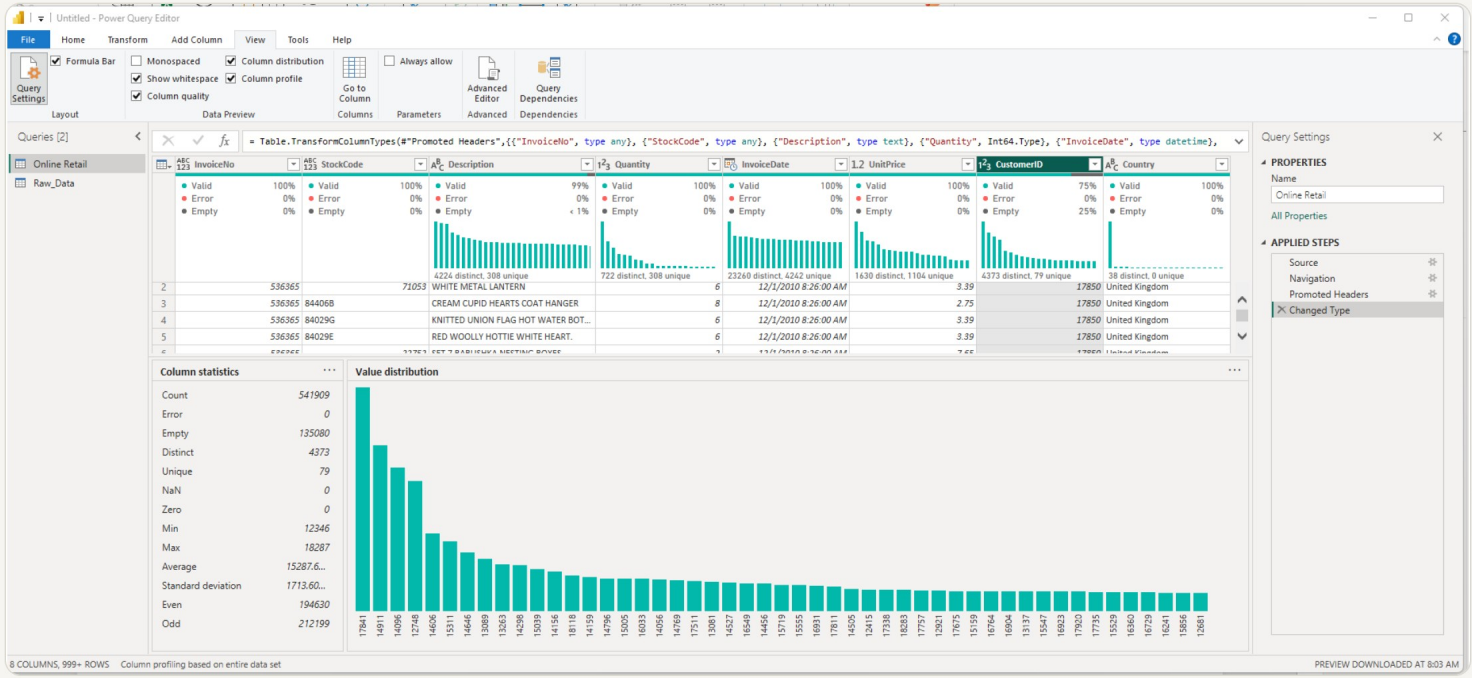
38
țări

InvoiceNo · StockCode · Description · Quantity · InvoiceDate · UnitPrice · CustomerID · Country

Magazin online din Regatul Unit · decembrie 2010 – decembrie 2011 · UCI Machine Learning Repository

PASUL 1 · PROFILARE

Profilarea datelor în Power Query



25%

CustomerID lipsă (135.080 rânduri)

−80.995

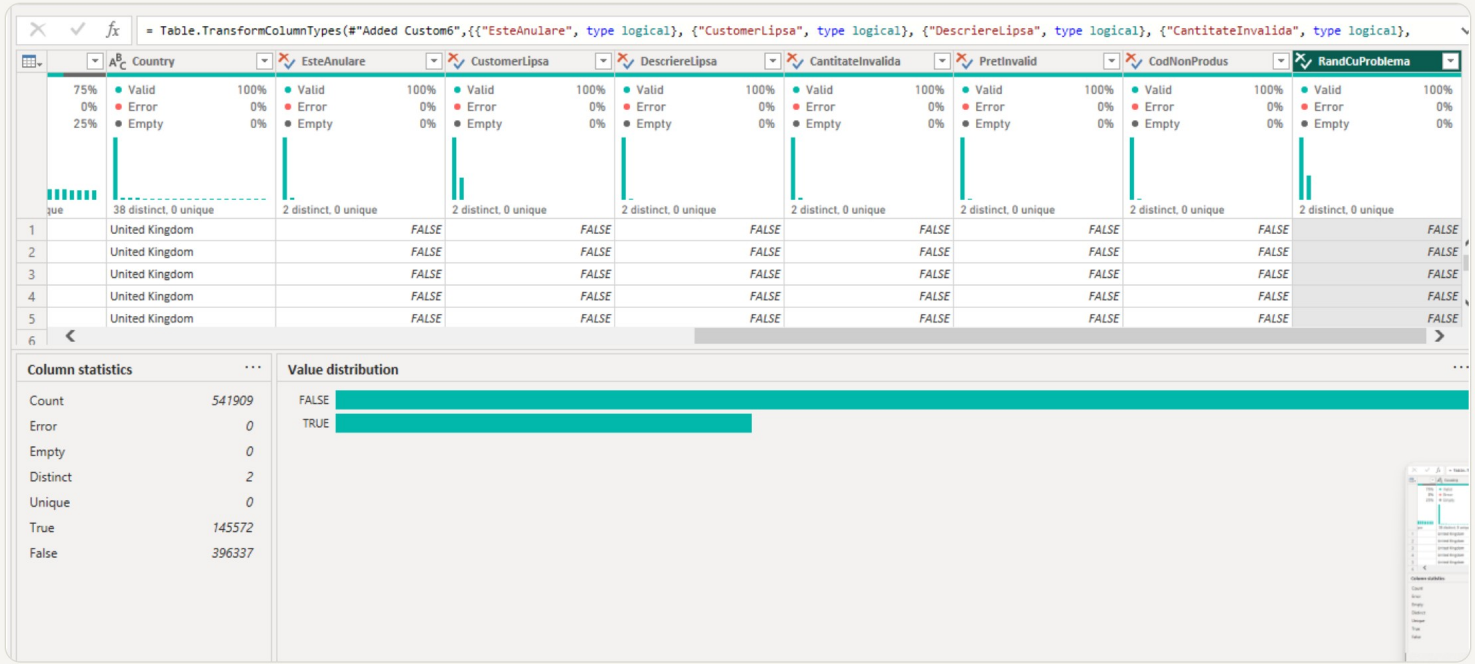
cantitatea minimă, deci retururi

4.224

descrieri distincte, prea multe

PASUL 2 · MARCARE

Marcăm problemele înainte să ștergem



145.572

rânduri cu cel puțin o problemă

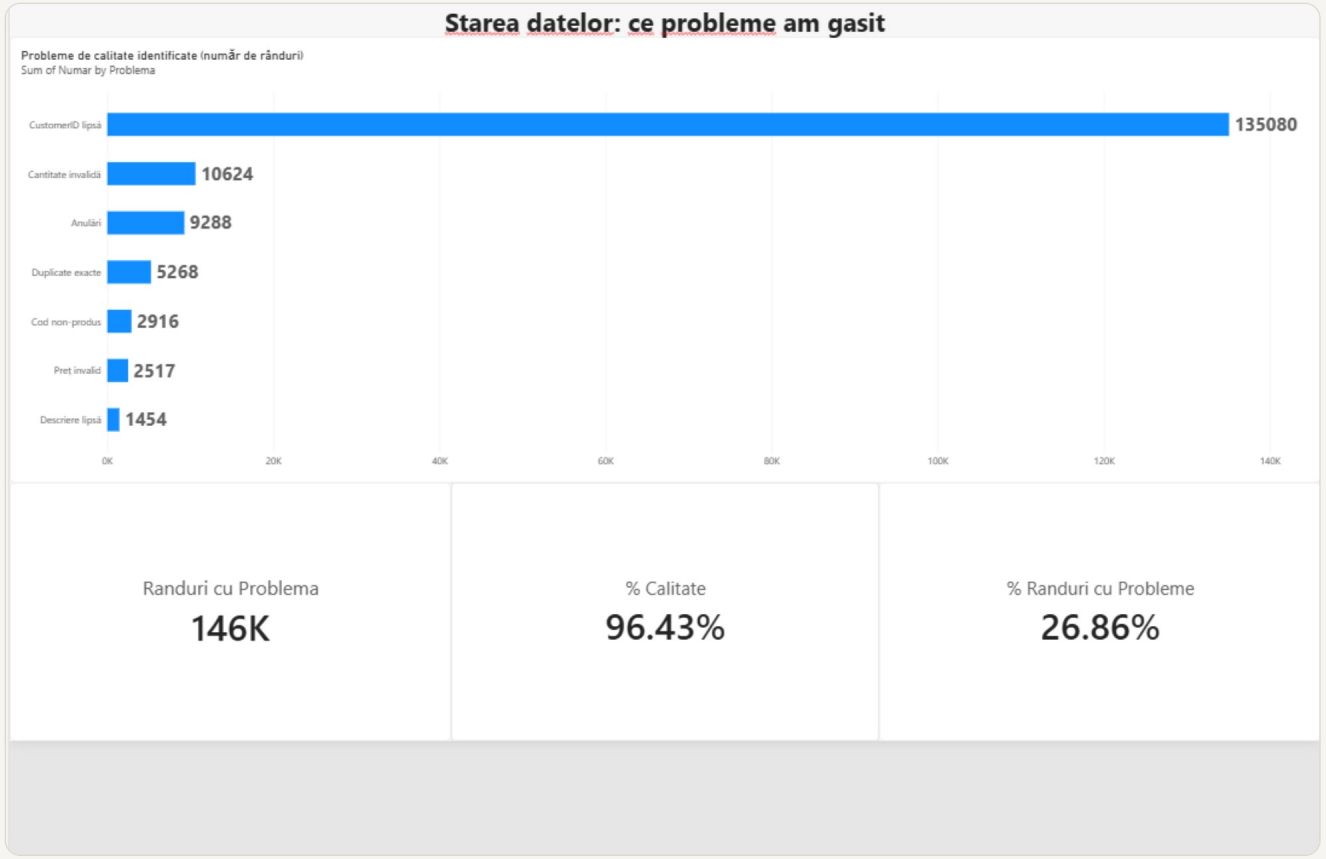
26,86%

din cele 541.909 de rânduri

O coloană flag (adevărat/fals) pentru fiecare problemă. Originalul rămâne neatins pentru comparația înainte/după.

DASHBOARD · PAGINA 1

Starea datelor: ce probleme am găsit



135.080
rânduri fără client: problema principală

26,86%
rânduri cu cel puțin o problemă

96,43%
rânduri păstrate după curățare

PASUL 3 · CURĂȚARE

Curățarea, pas cu pas

541.909
date brute

−5.268
duplicate

536.641
fără duplicate

−~13 mii
invalide

~523 mii
date curate (96,43%)

Eliminate

anulări, cantități și prețuri invalide, coduri non-produs, descrieri lipsă

Păstrate

rândurile fără CustomerID, etichetate „Necunoscut”: sunt vânzări reale

PASUL 4 · MASTER DATA MANAGEMENT

O singură înregistrare per entitate

Produse

3.803

produse unice, câte o descriere per cod (golden record). Înainte: 4.148 combinații cod–descriere.

Clienți

4.335

înregistrări: clienții identificați plus o înregistrare „Necunoscut”, cu tipul Identificat sau Neidentificat.

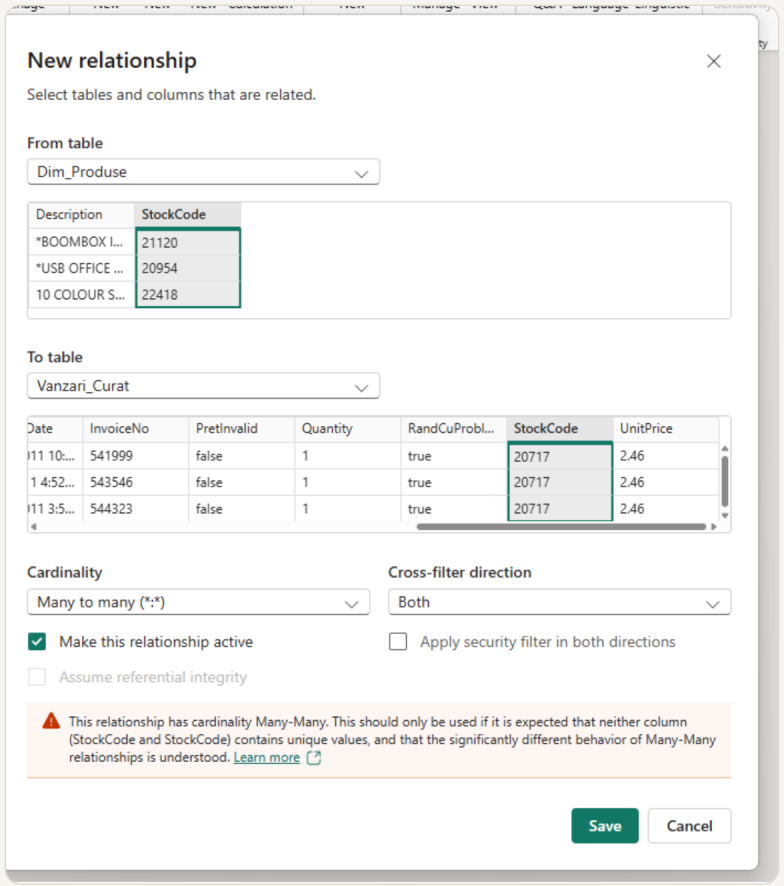
Țări

38

țări cu nume standard: EIRE devine Ireland, RSA devine South Africa, USA devine United States.

DESCOPERIRE PE PARCURS

Majusculele schimbă numărul de produse



4.148 combinații cod–descriere

3.912 coduri, după o descriere per cod

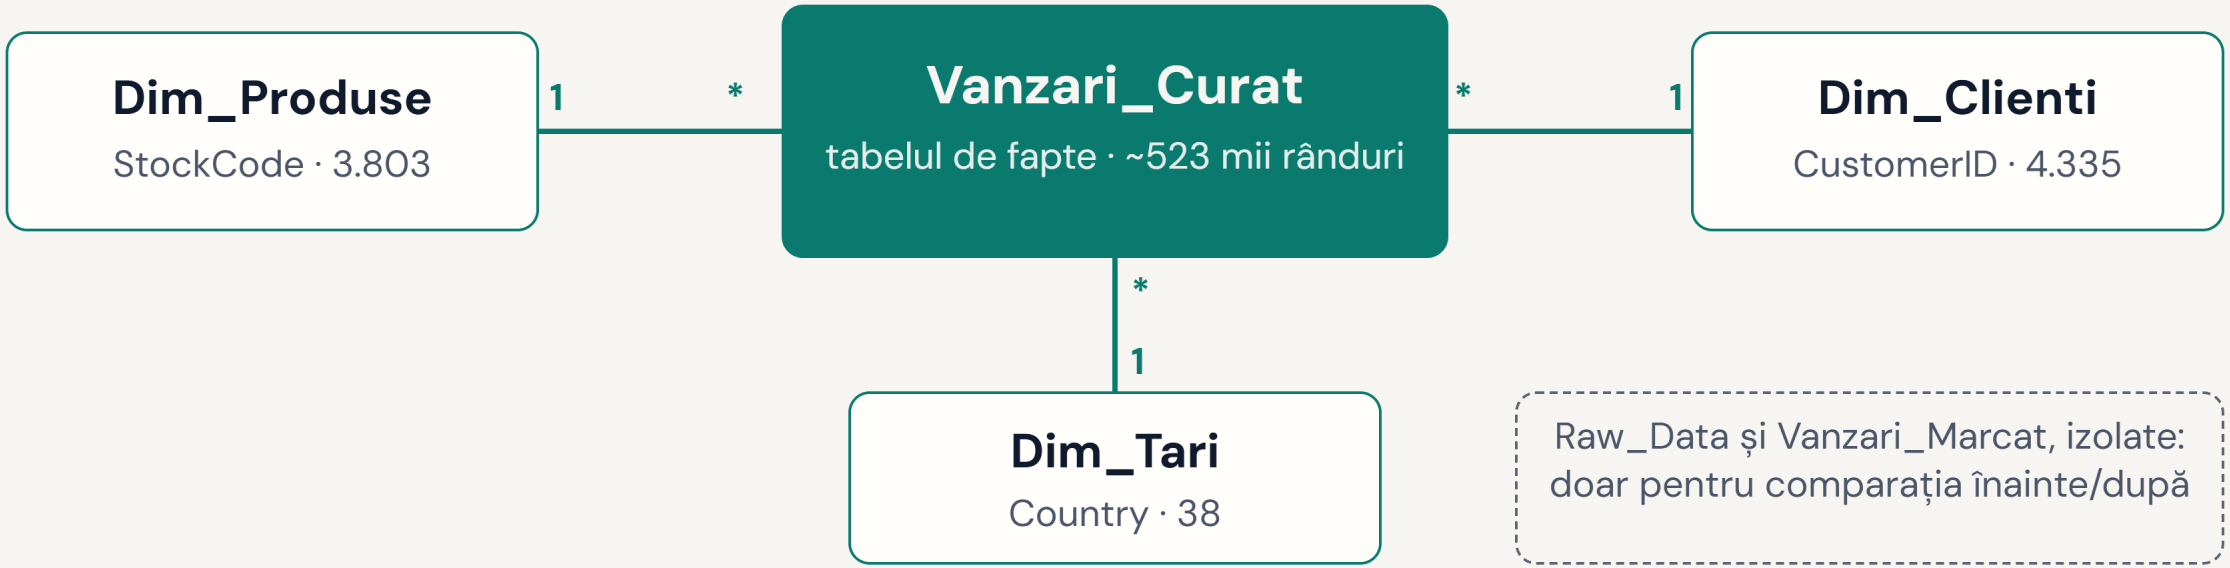
3.803 produse reale, după unificarea majusculelor

Power BI a refuzat relația unu-la-mulți până am unificat coduri precum 85123A și 85123a: 109 coduri în plus.

PASUL 5 · MODELUL DE DATE

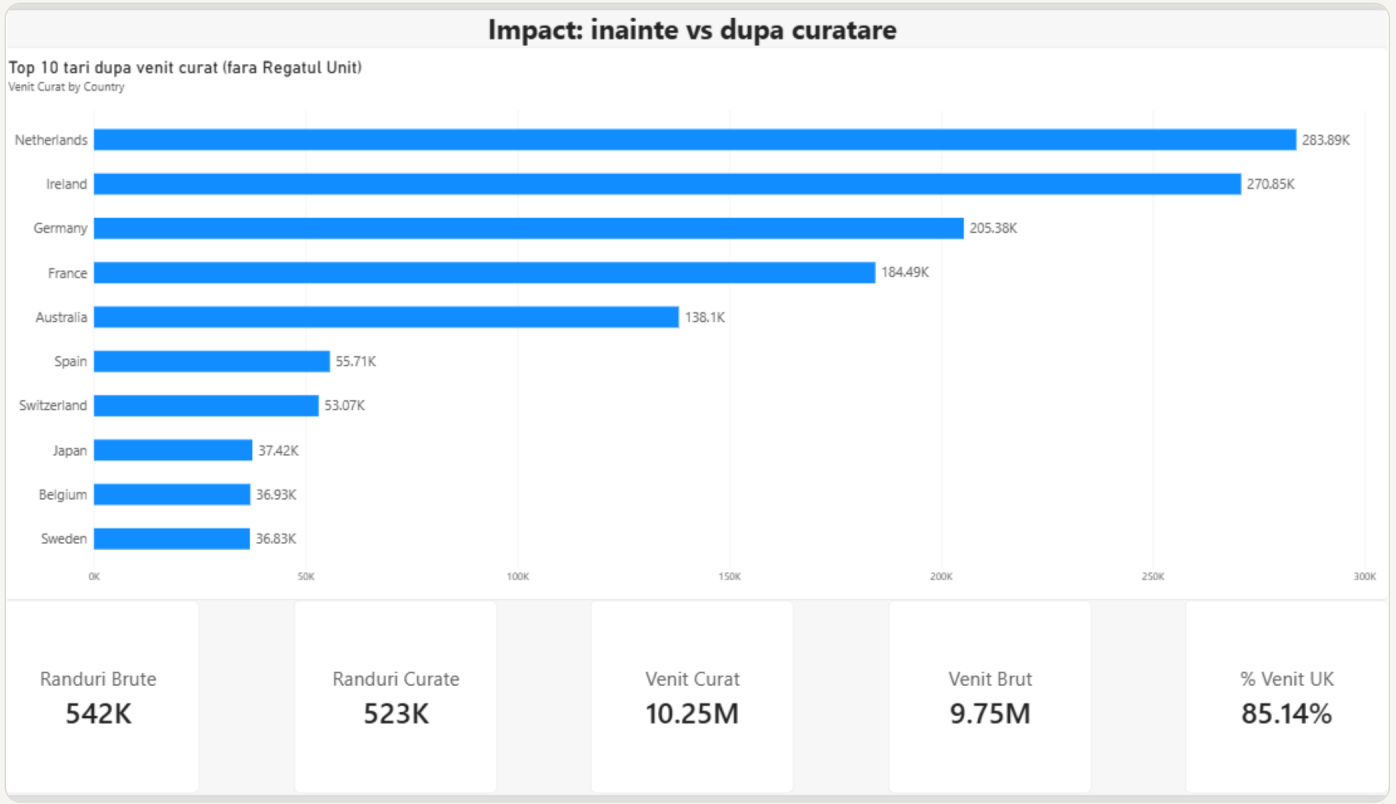
Model stea în Power BI

Trei tabele master legate de tabelul de fapte, relații unu-la-mulți cu filtrare într-o singură direcție.



DASHBOARD · PAGINA 2

Impact: înainte vs. după curățare



+5,1%

venit: 9,75 mil. brut, 10,25 mil. curat

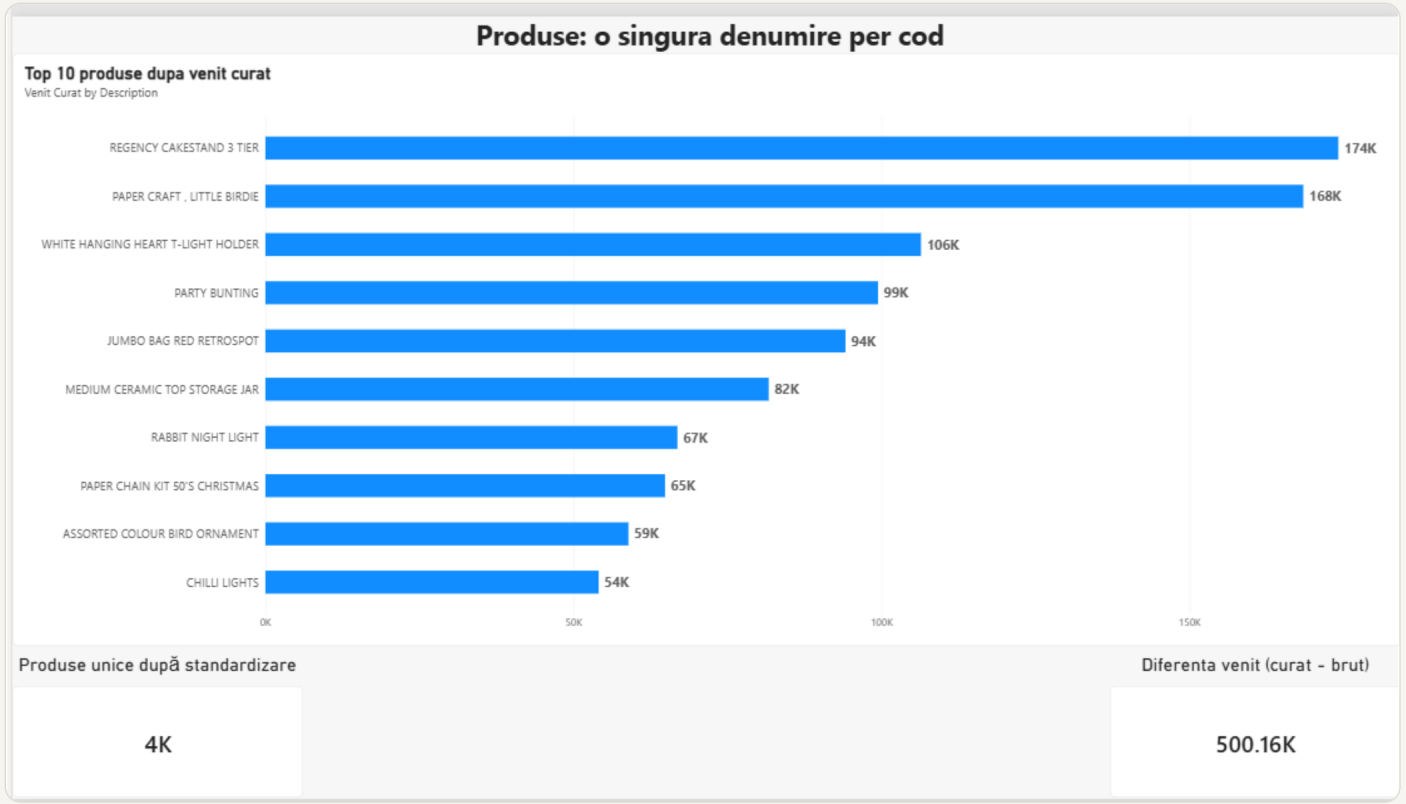
85,14%

din venit vine din Regatul Unit

În datele brute, retururile scădeau venitul. Graficul arată restul piețelor, fără Regatul Unit.

DASHBOARD · PAGINA 3

Produse: o singură denumire per cod



3.803
produse unice după standardizare

174 mii
REGENCY CAKESTAND 3 TIER, locul 1

Locul 2, PAPER CRAFT, LITTLE BIRDIE (168 mii), este o comandă anulată ulterior: o limită a analizei.

CONCLUZII

Ce am aflat și unde sunt limitele

1. Problema principală este completitudinea: 24,93% din rânduri nu au client.
2. Curățarea schimbă venitul cu +5,1%, iar tratarea retururilor trebuie decisă conștient.
3. MDM schimbă numărul entităților: 3.803 produse reale, nu 4.148.
4. Piața este concentrată: 85,14% din venit vine din Regatul Unit.

Limite

Anulările sunt scoase, dar nu și vânzările inițiale: venitul poate fi supraestimat.

Lista codurilor non-produs este făcută manual.

Descrierea per produs: regulă simplă, prima în ordine alfabetică.

Mulțumesc!